

Rispondere ad ogni domanda *nello spazio di metà facciata di foglio protocollo* (per domande 1-2) e *una facciata di foglio protocollo* (per domande 3-4)

Domanda 1 (punti 6): Dati i seguenti 3 documenti:

Doc1: “vado a scuola in bicicletta”

Doc2: “la bicicletta è parcheggiata”

Doc3: “solitamente parcheggio vicino a scuola”

Mostrare

- a) un potenziale output del preprocessing (indicando le fasi applicate)
- b) Il risultante inverted index nella versione document-based e word-based.

Domanda 2 (punti 6):

- a) Scrivere la formula di similarità del modello vettoriale fornendo una descrizione dei suoi argomenti
- b) Calcolare la similarità coseno tra Doc1 e Doc2 usando come pesi la formula tfxidf

Domanda 4 (punti 10):

- a) Elencare le misure di efficacia di un sistema di Information Retrieval che sono “sensibili” al ranking ovvero i cui valori dipendono dall’ordine dei risultati. Per ogni misura, descrivere brevemente come viene calcolata.
- b) Dati il seguente insieme di documenti rilevanti $R=\{d1,d4,d127,d3,d56\}$ e i seguenti ranking $Rank1=[d2,d1,d110,d56,d4]$ e $Rank2=[d1,d2,d56,d110,d4]$, mostrare i valori delle misure elencate precedentemente.

Domanda 5 (punti 10):

- a) Definire un q-gramma
- b) Descrivere le tecniche di tolerant retrieval che fanno uso dei q-grammi
- c) Mostrare un esempio a piacere per ogni tecnica di cui al punto (b).